

ANALIZA INVERZNEGA PROBLEMA PRI DOLOČANJU PARAMETROV KARDIOVASKULARNEGA SISTEMA IZ SINTETIČNIH ARTERIJSKIH PULZNIH VALOV

**ANALYSIS OF THE INVERSE PROBLEM FOR DETERMINING CARDIOVASCULAR SYSTEM PARAMETERS
FROM SYNTHETIC ARTERIAL PULSE WAVES**

Evgenija Burger

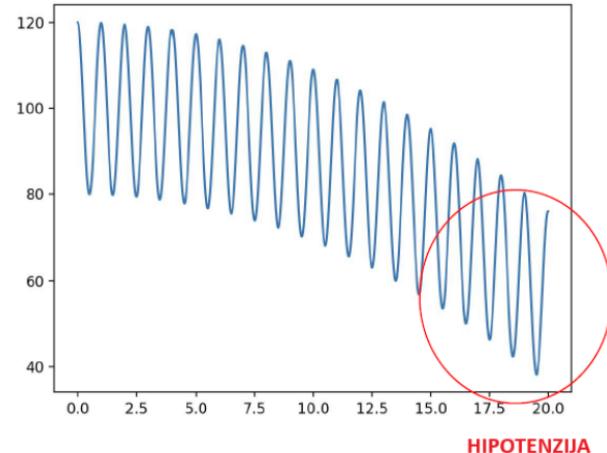
Mentor: prof. dr. Blaž Zupan
Somentor: doc. dr. Borut Kirn

Računalništvo in matematika,
UL FMF

24. 1. 2025

MOTIVACIJA

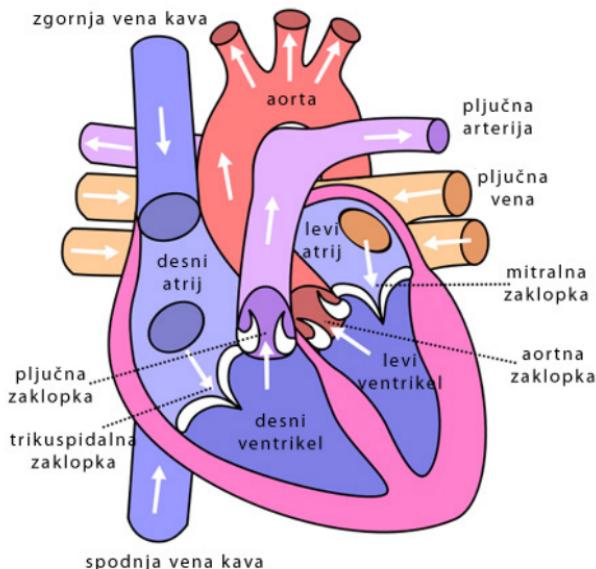
KRVNI TLAK IN ARTERIJSKI PULZNI VAL



HIPOTENZIJA

MOTIVACIJA

KRVNI TLAK IN ARTERIJSKI PULZNI VAL



Povečanje sistemске žilne upornosti,
večji upor → višji tlak

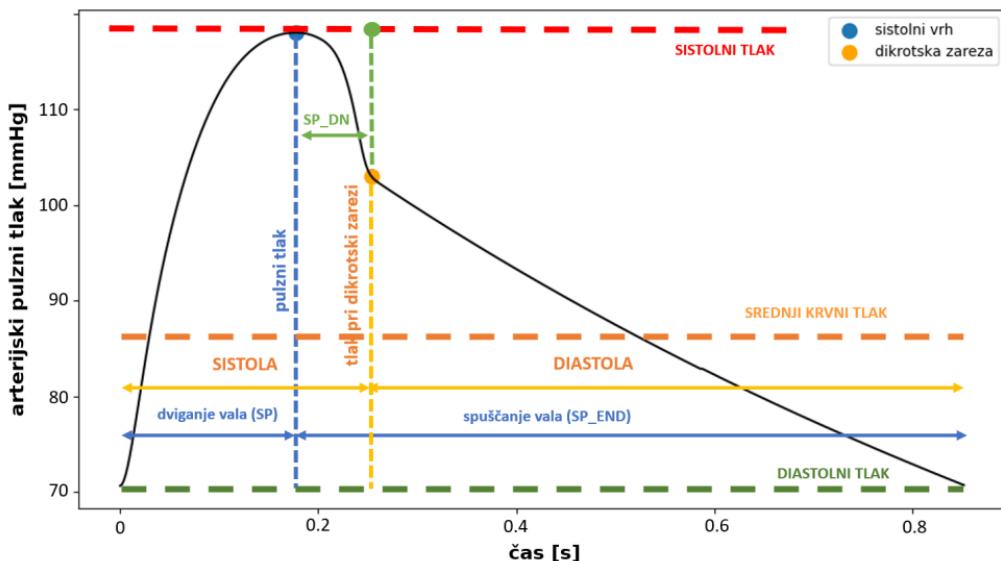
Dodajanje fiziološke raztopine v sistem
(ekvivalentno spremenjanju venske podajnosti),
manjša podajnost → višji tlak

Povečanje kontraktilnosti srca,
večja kontraktilnost → višji tlak

MOTIVACIJA

KRVNI TLAK IN ARTERIJSKI PULZNI VAL

Hypotension Prediction Index – Hatib in sod. (2018a)



POTEK DELA

Cilj magistrskega dela: raziskati, kako lahko matematično modeliranje in metode strojnega učenja pripomorejo k boljšemu razumevanju stanja kardiovaskularnega sistema na osnovi oblik arterijskih pulznih valov.

Potek raziskovanja:

- ▶ **simulacija in vizualizacija podatkov**
- ▶ **opis valov z značilkami**
- ▶ **reševanje inverznega problema s postopki strojnega učenja in določitev najpomembnejših značilk**
- ▶ **raziskovanje podatkov z grafičnim pristopom**

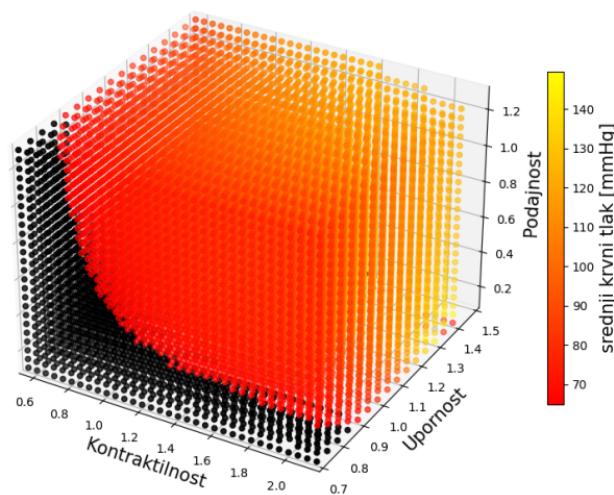
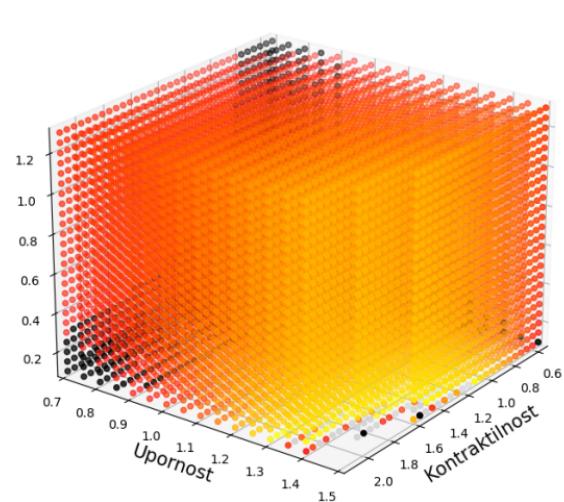
PODATKI

SIMULACIJA PODATKOV

- ▶ prost dostopen in uveljavljen matematičen model kardiovaskularnega sistema **CircAdapt**
- ▶ simulacije z različnimi vrednostmi parametrov, ki opisujejo **sistemsko žilno upornost**, **vensko podajnost** in **kontraktilnost**
- ▶ izvedli smo **14 025 simulacij** arterijskih pulznih valov, model je skonvergiral v 13 576 primerih

PODATKI

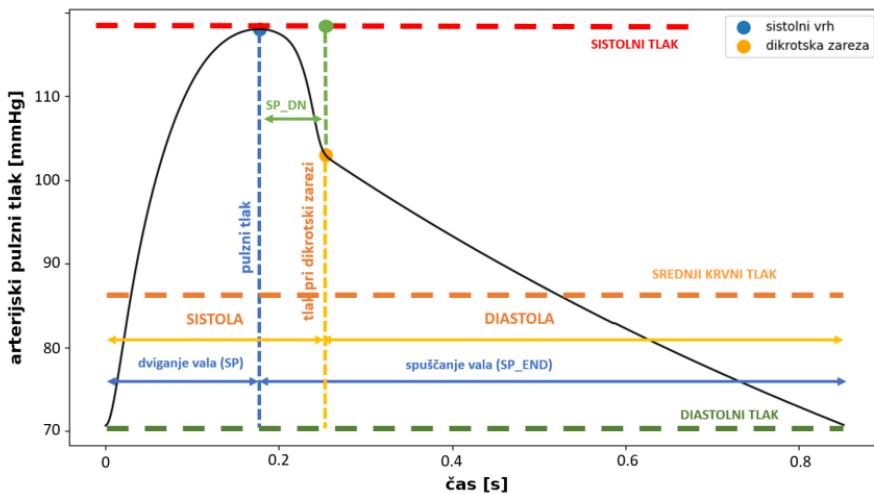
OPAZOVANJE OBMOČIJ Z NIZKIM KRVNIM TLAKOM



PODATKI

DEFINICIJA ZNAČILK

- ▶ fiziološke značilke
- ▶ značilke, povezane z vrednostjo krvnega tlaka
- ▶ značilke, povezane s časom
- ▶ površine pod krivuljo

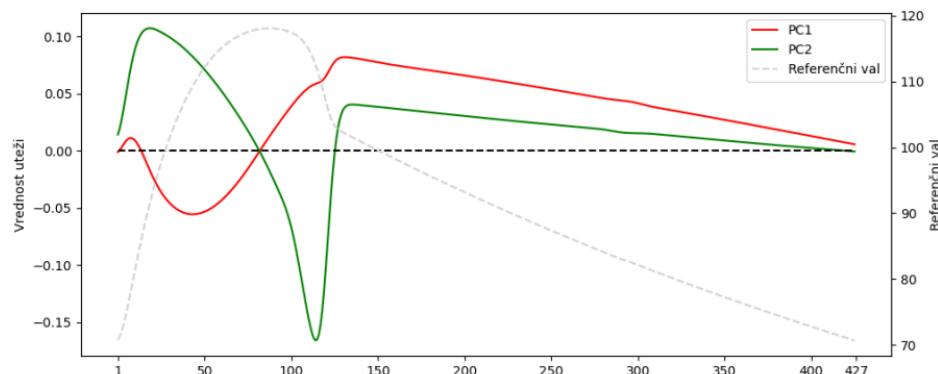


REZULTATI

REZULTATI ANALIZE GLAVNIH KOMPONENT NA TOČKAH VALOV

Prva glavna komponenta je pojasnila 70,65 % variance, druga komponenta pa 22,13 % variance - **skupaj 92,78 %.**

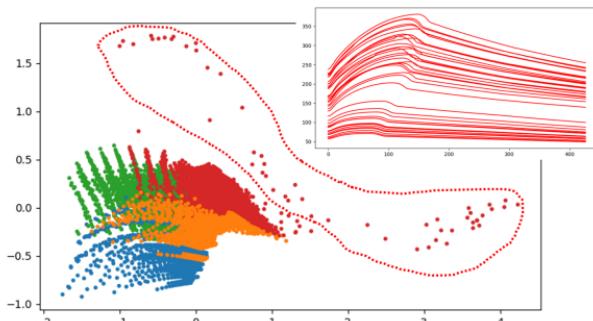
Opazovanje korelacijs med točkami valov in prvima glavnima komponentama:



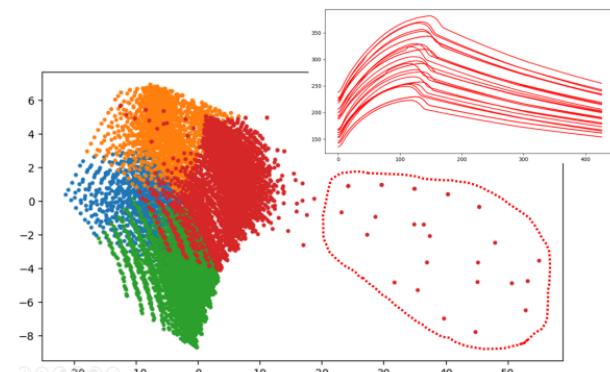
REZULTATI

REZULTATI ANALIZE GLAVNIH KOMPONENT NA ZNAČILKAH

Prva glavna komponenta je pojasnila 65,87 % variance, druga komponenta pa 25,58 % variance - skupaj **91,45 %**.



Slika. Projekcija valov, opisanih s točkami.



Slika. Projekcija valov, opisanih z značilkami.

Modra - kontraktilnost in upornost manjši od referenčne vrednosti 1, **oranžna** - kontraktilnost manjša in upornost večja od 1, **zelena** - kontraktilnost večja od 1 in upornost manjša, **rdeča** - obe vrednosti večji od 1.

REZULTATI

UPORABA ALGORITMOV STROJNEGA UČENJA

Metode strojnega učenja: **linearna regresija, L1 regularizirana regresija, XGBoost**

Vrednotenje uspešnosti: **10-kratno prečno preverjanje**

Ocenjevanje uspešnosti: **R^2** , ki se izračuna po enačbi:

$$R^2 = 1 - \frac{\sum_{i=1}^n (\hat{y}^{(i)} - y^{(i)})^2}{\sum_{i=1}^n (\hat{y}^{(i)} - \bar{y}^{(i)})^2}$$

REZULTATI

OCENA TOČNOSTI ALGORITMOV

	R^2 kontraktilnost	R^2 upornost	R^2 podajnost
linearna regresija	0,9961	0,9999	0,4271
L1 regularizirana regresija	≈ 1	≈ 1	0,32
algoritmom XGBoost	0,998	0,999	0,939

REZULTATI

REZULTATI NAPOVEDOVANJA Z LINEARNO REGRESIJO

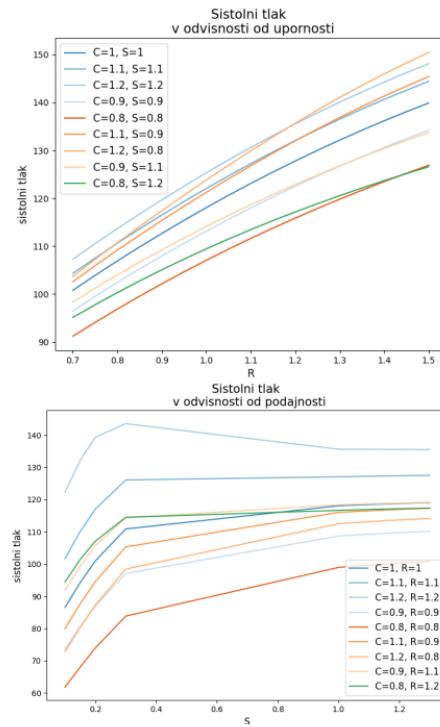
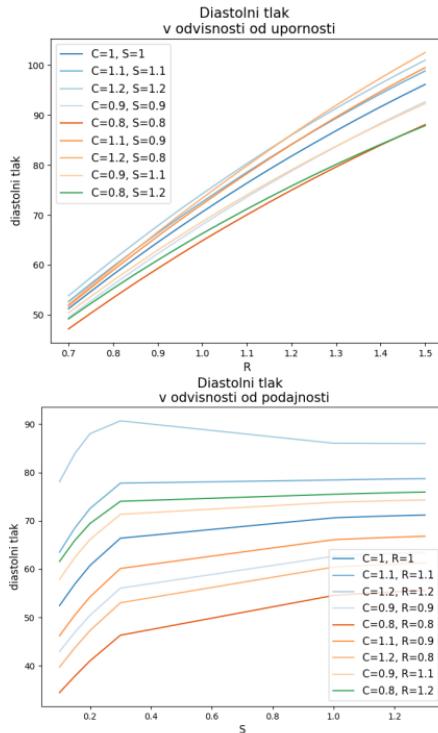
Cilj:

- ▶ oceniti, kako dobro lahko napovemo vrednosti parametrov
- ▶ preizkusiti majhne podmnožice najbolj osnovnih značilk

	R^2 kontraktilnost	R^2 upornost	R^2 podajnost
dbp, sbp	0,6732	0,9748	0,0183
pp, dbp, sbp, map	0,6732	0,9748	0,0185
pp, dbp, sbp, map, t_sp	0,9480	0,9790	0,0748
vse značilke	0,9961	0,9999	0,4271

REZULTATI

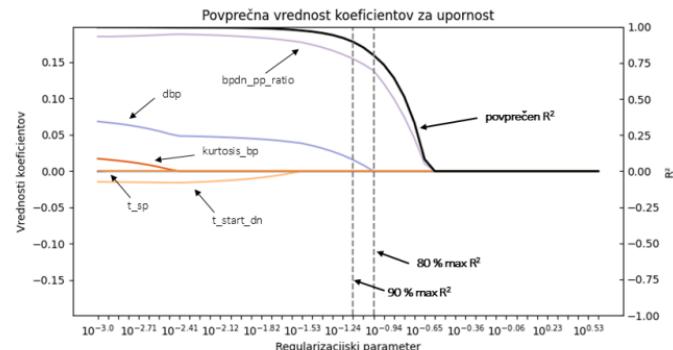
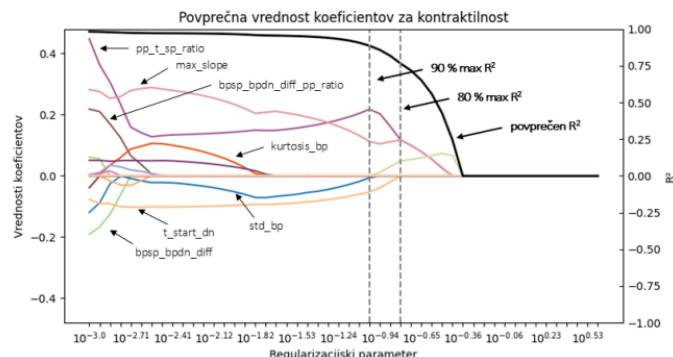
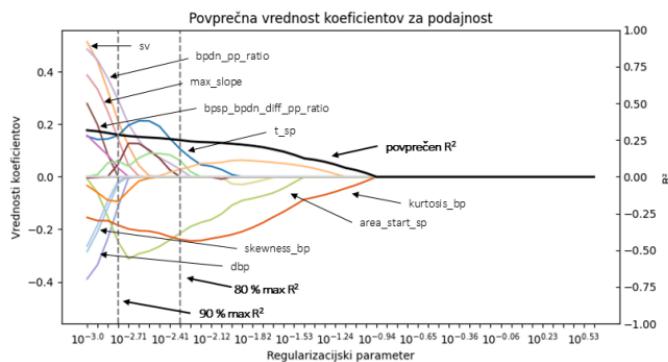
VREDNOSTI OSNOVNIH ZNAČILK V ODVISNOSTI OD VREDNOSTI PARAMETROV



REZULTATI

IZBOR ZNAČILK Z L1 REGULARIZIRANO REGRESIJO

Vrednosti α : 50 vrednosti, ki so enakomerno razporejene na logaritemski skali med 10^{-3} in $10^{0,6}$ ($\approx 3,981$)



REZULTATI

IZBOR ZNAČILK Z L1 REGULARIZIRANO REGRESIJO - POVPREČNE VREDNOSTI KOEFICIENTOV ZA ZNAČILKE

značilka	kontraktilnost			upornost			podajnost		
	R ²	0,9R ²	0,8R ²	R ²	0,9R ²	0,8R ²	R ²	0,9R ²	0,8R ²
bpdn_pp_ratio				0,19	0,14	0,15	0,49	0,03	0,29
max_slope	0,28	0,12	0,11				0,39		0,14
pp_t_sp_ratio	0,45	0,12	0,22						
sv							0,51		0,21
kurtois_bp				0,02			-0,15	-0,24	-0,18
dbp	0,00				0,07		0,02	-0,39	-0,11
area_start_sp	0,06						-0,01	-0,21	-0,25
bpsp_bpdn	0,22						0,28		
diff_pp_ratio									
t_sp		-0,01	0,00				0,15	0,11	0,16
bpsp_bpdn_diff	-0,19							0,06	0,06
skewness_bp							-0,29		-0,02
t_sp_dn							-0,26		-0,02
bpsp_bpdn							0,16		0,03

REZULTATI

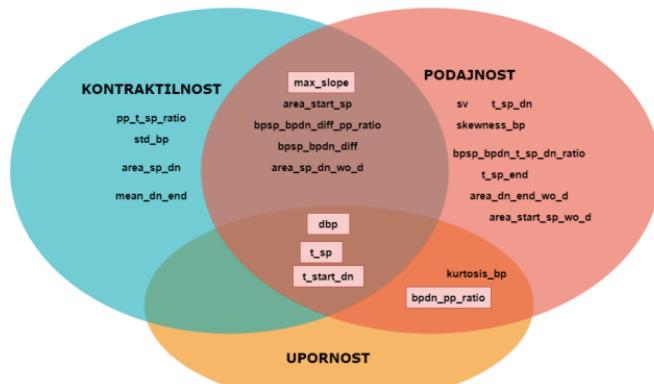
IZRAČUN POMEMBNOSTI ZNAČILK Z ALGORITMOM XGBOOST

Pojasnjevalna značilka	kontraktilnost	upornost	podajnost
pp_t_sp_ratio	13,0302		0,0624
area_start_sp_wo_d	0,0899		2,0001
bpdn_pp_ratio		1,8267	0,2275
bpsp_bpdn_t_sp_dn_ratio			1,8261
t_start_dn	0,5261	0,0207	1,2748
max_slope	1,6645		0,1004
area_sp_dn	1,3693	0,0137	0,0729
t_sp	0,3464		0,7814
dbp		0,0277	0,4556
skewness_bp		0,1672	0,3109
kurtois_bp			0,4506
d_bpdn_t_dn_end_ratio			0,4439
mean_sp_dn_wo_d	0,0283		0,3931
t_sp_dn	0,0237		0,3637
area	0,0437		0,3398
std_bp	0,0622		0,3026
area_start_sp			0,3149
area_dn_end	0,0143	0,0269	0,2551
mean_bp_wo_d			0,2767
sv			0,2683
area_sp_end	0,0163	0,0143	0,1943
pp			0,2059
bpsp			0,1963

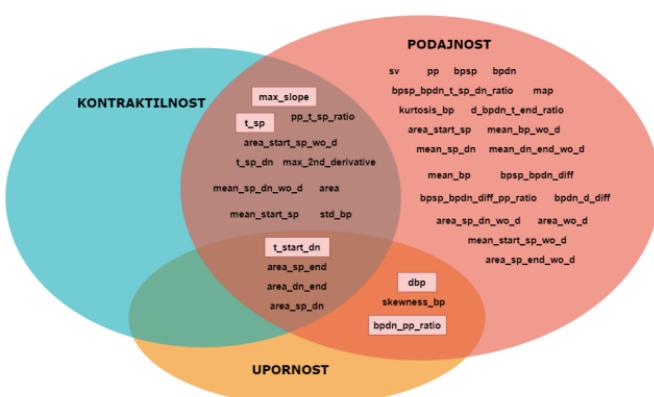
Zakaj smo pri algoritmu XGBoost tudi za podajnost dobili dobro oceno za točnost algoritma?

REZULTATI

ZDRAŽITEV REZULTATOV L1 REGULARIZIRANE REGRESIJE IN ALGORITMA XGBOOST



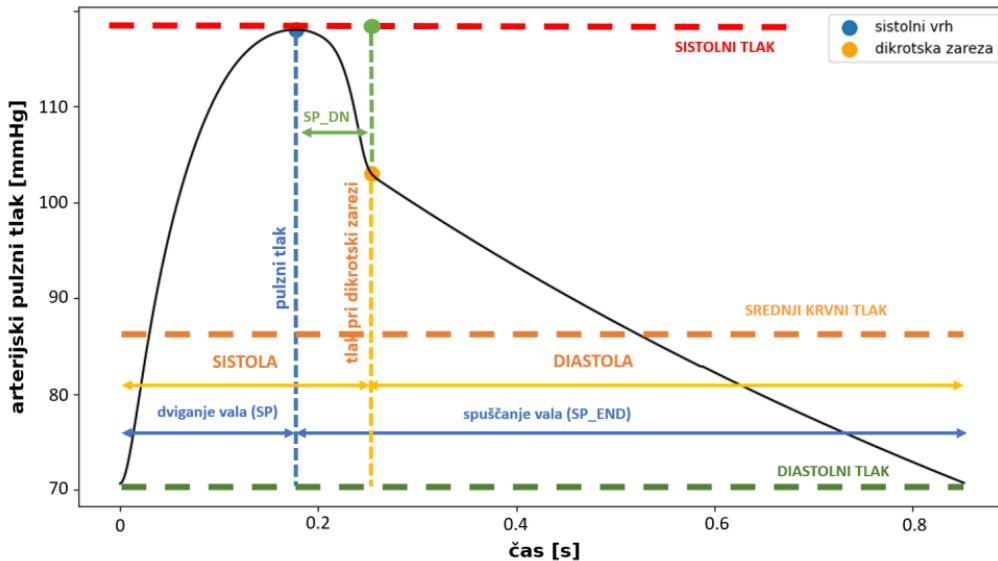
Slika. Značilke, ki so se izkazale za pomembne pri regularizirani regresiji.



Slika. Značilke, ki so se izkazale za pomembne pri algoritmu XGBoost.

REZULTATI

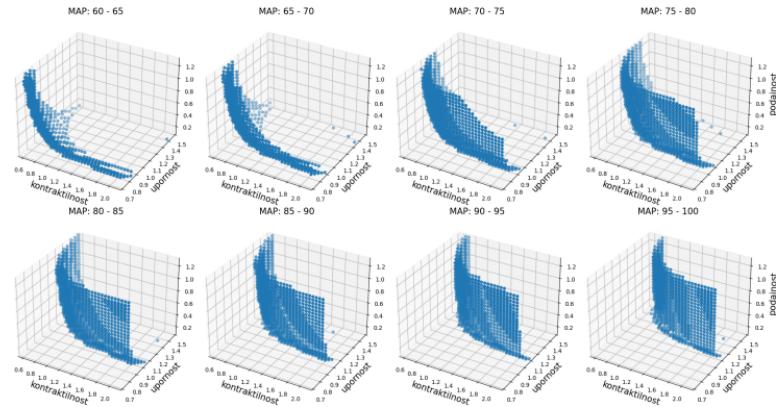
ZDRAŽITEV REZULTATOV L1 REGULARIZIRANE REGRESIJE IN ALGORITMA XGBOOST



REZULTATI

REZULTATI RAZISKOVANJA PROSTORA Z GRAFIČNIM PRISTOPOM

Spreminjanje inverznega prostora v odvisnosti od izbire značilk in njihovih vrednosti:

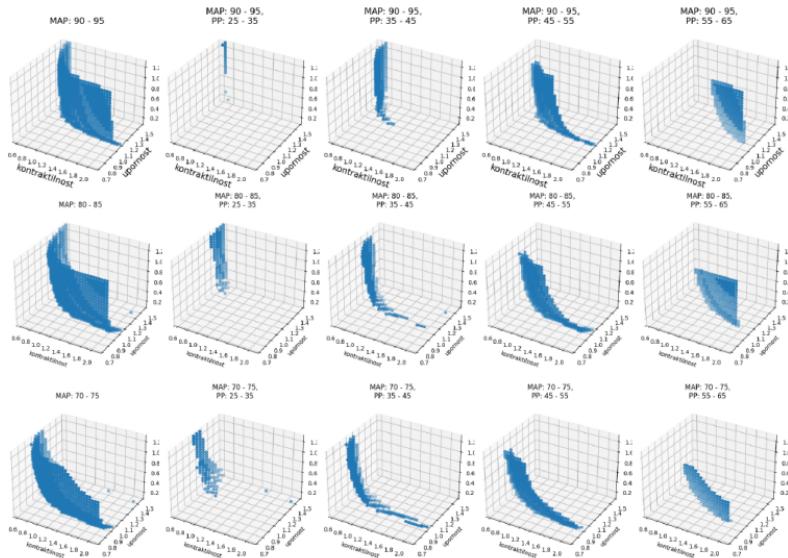


Dobljena oblika predstavlja **ploskev**.

REZULTATI

REZULTATI RAZISKOVANJA PROSTORA Z GRAFIČNIM PRISTOPOM

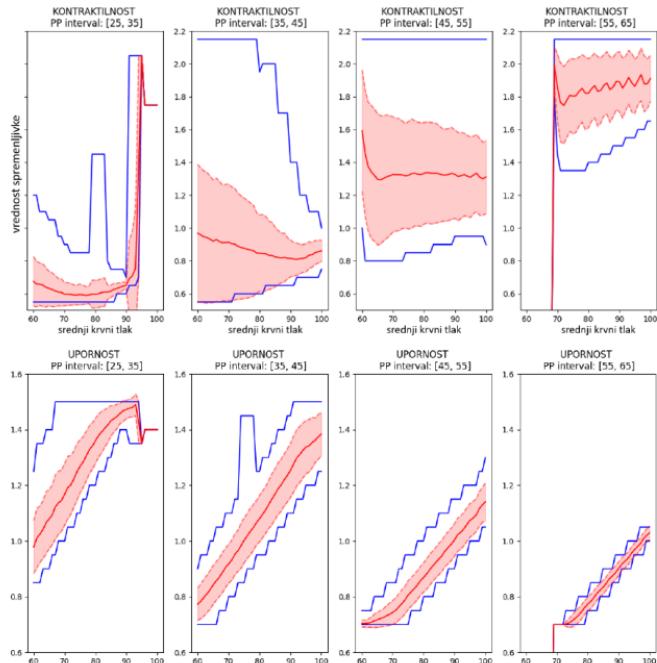
Priklučimo informacijo o pulznem tlaku:



Ali lahko vrednosti parametrov dovolj dobro opišemo že samo iz slik?

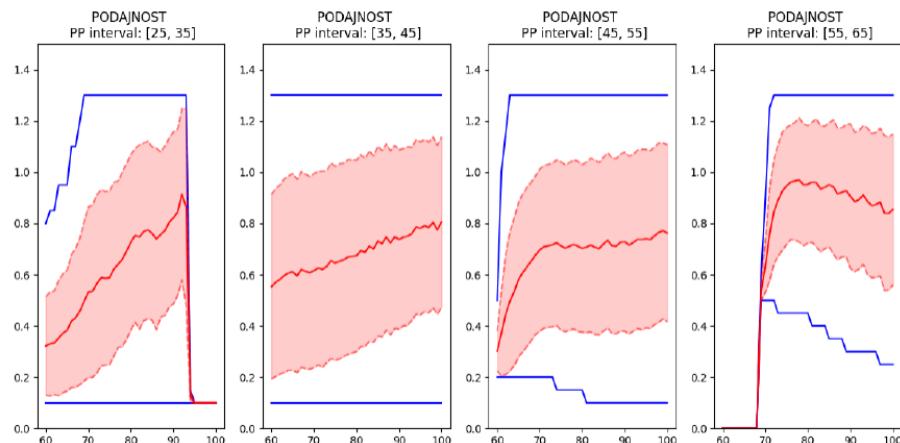
REZULTATI

KONTRAKTILNOST IN UPORNOST PRI RAZLIČNIH VREDNOSTIH SREDNJEGA IN PULZNEGA KRVNEGA TLAKA



REZULTATI

PODAJNOST PRI RAZLIČNIH VREDNOSTIH SREDNJEGA IN PULZNEGA KRVNEGA TLAKA



REZULTATI KODA

The screenshot shows a GitHub repository page for 'magistrska-naloga'. The repository is public and was last updated by 'evgenija' on 'eadBbb8' last month. It contains 10 commits across 1 branch and 0 tags. The repository structure includes 'data', 'machine_learning', 'simulations', 'visualisations', and a 'README.md' file. The 'README' section is titled 'Magistrska naloga' and states: 'Magistrsko naložilo smo izvedli v treh korakih.' Below this, a numbered list outlines the steps: 1. Simulacija podatkov, 2. Vizualizacija, 3. Analiza z algoritmimi strojnega učenja in grafičnega pristopa. A note at the bottom says: 'Koda za vsak posamezen razdelek se nahaja v svoji mapi.'

Code Issues Pull requests Actions Projects Wiki Security Insights Settings

magistrska-naloga Public

main 1 Branch 0 Tags Go to file Add file <> Code

evgenija update eadBbb8 · last month 10 Commits

data data last month

machine_learning update last month

simulations update last month

visualisations update last month

README.md Update readme last month

README

Magistrska naloga

Magistrsko naložilo smo izvedli v treh korakih.

1. Simulacija podatkov
2. Vizualizacija
3. Analiza z algoritmimi strojnega učenja in grafičnega pristopa

Koda za vsak posamezen razdelek se nahaja v svoji mapi.

About

No description, website, or topics provided.

Readme Activity 0 stars 1 watching 0 forks

Releases

No releases published Create a new release

Packages

No packages published Publish your first package

Languages

Jupyter Notebook 90.9% Python 6.0%

MATLAB 3.0% R 0.1%

Suggested workflows

Based on your tech stack

DISKUSIJA IN ZAKLJUČEK

GLAVNE UGOTOVITVE

1. Z algoritmi strojnega učenja lahko na naših podatkih **zelo dobro napovemo vrednosti vseh treh parametrov**, vendar za to potrebujemo dovolj kompleksen model, kot je XGBoost.
2. Med značilkami, ki so se izkazale za pomembne za napovedovanje vsakega posameznega parametra, **smo našli značilke, ki so bile skupne vsem trem parametrom**.
3. Zgolj iz vrednosti značilk in njihovih okvirnih negotovosti **lahko opišemo rešitveni prostor v obliki ploskev**, ki pa nam ne povejo točne vrednosti parametrov.

LITERATURA

- Hatib, F., Jian, Z., Buddi, S., Lee, C., Settels, J., Sibert, K., Rinehart, J., & Cannesson, M. (2018a). **Machine-learning Algorithm to Predict Hypotension Based on High-fidelity Arterial Pressure Waveform Analysis.** *Anesthesiology*, 129(4), 663–674.
- Hatib, F., Jian, Z., Buddi, S., Lee, C., Settels, J., Sibert, K., Rinehart, J., & Cannesson, M. (2018b). **Machine-learning Algorithm to Predict Hypotension Based on High-fidelity Arterial Pressure Waveform Analysis.** *Anesthesiology*, 129(4), 663–674.
- Mulder, M. P., Broomé, M., Donker, D. W., & Westerhof, B. E. (2022). **Distinct morphologies of arterial waveforms reveal preload-, contractility-, and afterload-deficient hemodynamic instability: An in silico simulation study.** *Physiological Reports*, 10(7), e15242.
- Piccioli, F., Valiani, A., Alastrauey, J., & Caleffi, V. (2022). **The effect of cardiac properties on arterial pulse waves: An in-silico study.** *International Journal for Numerical Methods in Biomedical Engineering*, 38(12), e3658.
- Zhao, A., Elgendi, M., & Menon, C. (2022). **Machine learning for predicting acute hypotension: A systematic review.** *Frontiers in Cardiovascular Medicine*, 9.